

La **statistique** est la science qui recueille, traite et analyse des données pour tirer des conclusions générales. Cette année nous étudions les **statistiques à une variable** c'est-à-dire les séries de données où un seul paramètre change.

Exemple:

- La liste des tailles des élèves d'une classe est une série statistique à une variable.
- La liste des tailles et du genre des élèves d'une classe est une série statistique à deux variables.
- La liste des poids, vitesses maximales et années de production de voitures est une série statistique à trois variables.

I. Représentation des séries statistiques

1. Organisation dans un tableau

Une série statistique à une variable peut être organisée dans un **tableau de fréquence** qui pour chaque valeur prise par le paramètre étudié associe son **effectif**, le nombre de fois où cette valeur a été rencontrée.

Taille des élèves (en m)	Centre des classes (x_i)	Effectifs (n_i)
[1, 60; 1, 65[	$\frac{1-0}{2} = 0,5$	2
[1, 65; 1, 70[		
[1, 70; 1, 75[		
[1, 75; 1, 80[		
[1, 80; 1, 85[		
Total :		

Paramètre X	Effectifs (n_i)
X_1	n_1
X_2	n_2
X_3	n_3
Total	$N = n_1 + n_2 + n_3$

Lorsque le paramètre est **mesurable de façon continue** (c'est-à-dire

), on regroupe les données par **classes** : ce sont des intervalles notés entre crochets $[a;b[$, a étant **inclus** () dans l'intervalle et b **exclu** () de l'intervalle.

Problème:

Voici la liste des tailles mesurées pour des élèves : 1,62 m, 1,67 m, 1,71 m, 1,6 m, 1,78 m, 1,67 m, 1,74 m, 1,8 m, 1,69 m et 1,76 m. Compléter le tableau ci-dessus.

2. Représentation graphique

Une série statistique peut être représentée par différents types de graphique :




Diagramme en bâton




Diagramme circulaire




Diagramme à ligne brisée

II. Indicateurs de position

On peut utiliser plusieurs mesures appelées **indicateurs** pour décrire une série statistique. Ils peuvent être calculés à la main mais en pratique on utilise souvent les fonctions statistiques d'un tableur ou de la calculatrice.

1. Mode

Le **mode** est la valeur de la variable statistique qui a le plus grand effectif (il peut y avoir plusieurs modes).

Problème:

Dans la série des tailles d'élèves, le mode est

2. Classe modale

Dans le cas où la distribution statistique est faite à l'aide de classes, la **classe modale** est la classe qui contient le plus grand effectif.

Problème:

Dans la série des tailles d'élèves, la classe modale est

3. Moyenne

La **moyenne** $\bar{x}$ est la valeur théorique qui pourrait remplacer toutes les valeurs de la série sans changer la somme totale. On la calcule à l'aide des formules suivantes :

$$\bar{x} = \frac{\text{somme de toutes les valeurs}}{\text{nombre total de valeurs } N} = \frac{X_1 \times n_1 + X_2 \times n_2 + \dots}{N}$$

C'est-à-dire :

- La somme de toutes les mesures divisée par le nombre de mesures.
- La somme des valeurs des mesures multipliée par leurs effectifs, divisée par le nombre total de mesures.

Dans le cas des séries où les caractères sont rangés par classes, on convient par approximation que toutes les valeurs appartenant à une même classe sont égales à la valeur du centre de classe x_i .

Problème:

1. Calculer la taille moyenne des élèves en prenant en compte la série totale :

2. Calculer la taille moyenne des élèves en prenant en compte la série répartie par classe :


4. Médiane

La **médiane** M_e d'une série statistique est le nombre qui partage cette série en deux séries de même effectif. La moitié des effectifs (50 %) a donc une valeur du caractère en dessous ou égale à la valeur médiane et l'autre moitié (50 %) au-dessus ou égale.

5. Les quartiles

Le **premier quartile** Q_1 , la médiane M_e et le **troisième quartile** Q_3 partagent les valeurs ordonnées de la série en quatre parties égales.

- Le **premier quartile** Q_1 est la plus petite donnée de la série pour laquelle au moins 25 % des données (soit $\frac{1}{4}$) sont inférieures ou égales à Q_1 .
- Le **troisième quartile** Q_3 est la plus petite donnée de la série pour laquelle au moins 75 % des données (soit $\frac{3}{4}$) sont inférieures ou égales à Q_3 .



Problème:

On donne le diagramme des effectifs cumulés pour les tailles des élèves (attention ce n'est pas le même que les diagrammes en 1.2). Sur celui-ci indiquer la médiane M_e ainsi que les premier et troisième quartiles Q_1 et Q_3 .





Diagramme des effectifs cumulés en fonction de la taille des élèves.

III. Indicateurs de dispersion

La dispersion d'une série statistique mesure à quel point la série est étendue sur une grande plage de valeurs, ou au contraire centrée sur une valeur particulière.



1. Étendue

L'**étendue** d'une série statistique est la différence entre son **maximum** (sa plus grande valeur) et son **minimum** (sa plus petite valeur).

2. Écart-type

L'**écart-type** σ est un *indicateur de dispersion associé à la moyenne*. Il traduit une moyenne d'écarts autour de la valeur moyenne $\bar{x}$. Plus l'écart-type est grand, plus la dispersion des données est grande.

3. Écart interquartile

L'écart interquartile $Q_3 - Q_1$ est un *indicateur de dispersion associé à la médiane*. C'est l'écart maximal entre les valeurs de la moitié centrale de la série. Plus l'écart interquartile $Q_3 - Q_1$ est grand, plus la dispersion des données est grande.

4. Diagramme en boîte à moustaches

Le **diagramme en boîte à moustaches** représente certains indicateurs d'une série.

Il est composé :

- d'un rectangle, la « boîte » qui encadre les quartiles Q_1 et Q_3 , et contient la médiane.
- de deux lignes, les « moustaches » qui donnent les valeurs extrêmes (minimum et maximum).

Problème:

Représenter la boîte à moustaches associée aux tailles des élèves.

